

Generative Adversarial Networks (GAN)


Olivier Ricou

2022

Deepfake

Les GAN permettent de créer de faux surprenant avec des réseaux profonds (d'où *Deepfakes*).


- création de visages (StyleGAN)



- fausse vidéo comme celle de [Poutine soulignant la faiblesse des démocraties.](#)

Autoencodeurs

Avant les GAN il y a eu les autoencodeurs qui ne demandent pas de vérité terrain.



Les résultats sont mauvais :





Figure 1: Reconstructions from layer FC6 of AlexNet with different losses.


U-net

U-net est une sorte d'autoencodeur avec une vérité terrain et des ponts.



Autoencodeur variationnel (VAE)

On découpe l'espace latent en sa moyenne et son écart type.



Pour construire ce réseau on définit 2 fonctions d'erreur :


- distance image d'arrivée / image de départ (cf autoencodeur)
- divergence de Kullback-Leibler entre le vecteur de l'espace latent et une gaussienne type : $KL(N(\mu, \sigma), N(0, I))$.

$$E = \alpha E_{\text{reconstruction}} + \beta [\text{mean}^2 + \text{std_deriv}^2 - \log(\text{std_deriv}^2) - 1]$$

VAE - génération

On peut créer de nouvelles images en gardant la moyenne et en modulant l'écart type $z = \mu + \varepsilon \sigma$.

Avec les chiffres manuscrits et un espace latent à 2 dimensions $[\mu, \sigma]$ on a :




<https://keras.io/examples/generative/vae/>

Vector Quantised-Variational AutoEncoder (VQ-VAE)

On fabrique une collection de vecteurs latents (*codebook* qui génère l'*embedding space*) qui est apprise lors de l'entraînement.

Si la sortie de l'encodeur est de $32 \times 32 \times 50$ alors la collection a des vecteurs de dimension 50. On choisit K vecteurs pour la collection.

On traduit la sortie de l'encodeur en prenant pour chaque valeur, la plus proche dans la collection $\rightarrow$ discrétisation & réduction des possibles.



VQ-VAE Compression




Figure 2: Left: ImageNet 128x128x3 images, right: reconstructions from a VQ-VAE with a 32x32x1 latent space, with $K=512$.

Un facteur de compression de 42 :

- l'image d'origine a 128x128x3x8 bits
- l'image est encodée avec 32x32x9 bits (521 valeurs possibles)
- (il faut aussi stocker la collection de valeurs soit $512 \times D$)

On peut entrainer un classifieur sur les images 32x32x1, ça marche.

VQ-VAE-2 – Multi-échelle





Figure 3: Reconstructions from a hierarchical VQ-VAE with three latent maps (top, middle, bottom). The rightmost image is the original. Each latent map adds extra detail to the reconstruction. These latent maps are approximately 3072x, 768x, 192x times smaller than the original image (respectively).

GAN


Un Generative Adversarial Network (GAN) est un encodeur avec un **discriminateur** qui indique si le résultat est un vrai ou un faux.



L'erreur du discriminateur permet qu'il se corrige (minimise l'erreur E_d) et que le générateur se corrige (maximise l'erreur du discriminateur).

Conditional GAN


Le principe est d'enrichir un GAN en ajoutant des informations supplémentaires (la classe de l'image par ex.) en entrée du générateur et du discriminateur.



On a ainsi des images plus réalistes en sortie.

Pix2Pix

Pix2pix est un GAN conditionnel.



Le générateur est un réseau en U et le discriminateur un classifieur CNN adapté.

On peut ainsi générer des images à partir de dessins.


Cycle GAN

Peut-on faire de l'auto-apprentissage (sans vérité terrain) avec un GAN?


Si le but est de passer d'un type d'image à un autre, c'est possible.

Pour cela on utilise 2 générateurs, G et F , et 2 discriminateurs, D_X et D_Y :


- G fabrique une image de type Y à partir d'une image de type X
- F fabrique une image de type X à partir d'une image de type Y
- D_X indique si l'image donnée est vraie ou a été générée par F
- D_Y indique si l'image donnée est vraie ou a été générée par G



CycleGAN – application



StyleGAN



Transformation $\mathbf{z} \mapsto \mathbf{w}$




Figure 6. Illustrative example with two factors of variation (image features, e.g., masculinity and hair length).

$$\mathbf{A} : \mathbf{w} \mapsto \mathbf{y} = \alpha \mathbf{w} + \beta$$

then $\mathbf{y} = (\mathbf{y}_s, \mathbf{y}_b)$

$$\text{AdaIN}(x_i, \mathbf{y}) = y_{s,i} \frac{x_i - \mu(x_i)}{\sigma(x_i)} + y_{b,i}$$

<https://github.com/NVlabs/stylegan>

StyleGAN – mélange de style

Avec 2 vecteurs de l'espace latent on peut mélanger 2 visage en injectant le 1er jusqu'à une couche dans la synthèse, puis le second.



Plus on injecte tard le 2e, moins l'impact est important (seulement dans les hautes fréquences).

StyleGAN – vers le visage moyen

Lorsqu'on est dans l'espace $\mathcal{W}$ avec une valeur latente $\mathbf{w}$ on peut interpoler avec le visage moyen $\bar{\mathbf{w}}$:

$$\mathbf{w} = \bar{\mathbf{w}} + \psi(\mathbf{w} - \bar{\mathbf{w}})$$



$\psi = 1$

$\psi = 0.5$

$\psi = 0$

$\psi = -0.5$

$\psi = -1$

StyleGAN 3



StyleGAN gère mal les hautes fréquences, problème que corrige StyleGAN 3.

<https://github.com/NVlabs/stylegan3>